

下面给你一套“遗传算法式（选择-交叉-变异-融合）群体句子演化”的过程指标 + 公式，目标是最终能输出：

- 1. 每一代（每一轮）创意熵曲线
- 2. 同一组初始句子集（相同 seed set）在不同实验组/不同 run 下得到的最终创意熵可比较

我会用统一记号，方便你直接落地到 Excel 或代码。

0) 记号与过程抽象

- 一次实验 run: 从初始句子集合 $S^{(0)} = \{s_1^{(0)}, \dots, s_n^{(0)}\}$ 出发, 经过 G 代得到最终结果集合 $S^{(G)} = \{s_1^{(G)}, \dots, s_n^{(G)}\}$ (你说“最后每个人都会得到最终结果”, 所以是 size=n 的最终集合)。
- 第 g 代 (或第 g 轮) 有群体 $S^{(g)}$ 。
- 选择: 从上一代选父代对 $(p_{k,1}^{(g)}, p_{k,2}^{(g)})$
- 交叉: 生成子代 $c_k^{(g)} = \text{Cross}(p_{k,1}, p_{k,2})$
- 变异: $m_k^{(g)} = \text{Mutate}(c_k^{(g)})$
- 最终写回/分配到个体: 形成下一代 $S^{(g+1)}$

你研究的是创意熵，所以你需要同时刻画：

- 目标约束达成 (任务B: 更符合要求)
- 新意/意外度 (语义跳跃)
- 群体多样性 (探索程度)
- 选择压力/收敛速度 (是否“坍缩到中庸”)
- 交叉与变异对新意的贡献 (过程归因)

1) 基础可计算量（所有过程指标的积木）

1.1 目标满足度 (fitness / constraint)

$$F(x) \in [0, 1]$$

由人工/分类器/规则得到（诗意度、正式度、简洁度等）。

1.2 embedding 与距离

- 向量: $E(x)$
- 相似: $\cos(E(x), E(y))$
- 距离 (新意用) : $d(x, y) = 1 - \cos(E(x), E(y))$

1.3 编辑幅度（变异强度常用）

$$e(x, y) = \frac{\text{EditDist}(x, y)}{\max(|y|, 1)}$$

2) 每一代的“创意熵”核心指标与公式

你要的是“过程曲线”，所以建议每一代算一个 **Creative Entropy of Generation**：
它由 (A) 群体多样性熵 + (B) 平均新意 + (C) 目标增益 - (D) 过度收敛惩罚 组成。

2.1 群体多样性（探索度）

(1) 平均 pairwise 距离（推荐最稳）

$$D^{(g)} = \frac{2}{n(n-1)} \sum_{i < j} d(s_i^{(g)}, s_j^{(g)})$$

(2) 信息熵版本（更像“熵”，推荐写论文用）

先把句子 embedding 聚类成 K 类（或网格化），令第 k 类占比为 $p_k^{(g)}$ ，则：

$$H^{(g)} = - \sum_{k=1}^K p_k^{(g)} \log(p_k^{(g)} + \epsilon)$$

解释： $H^{(g)}$ 越大，群体表达方向越分散（创意探索更强）。

2.2 代际新意（“这一代相对上一代跳了多少”）

$$N^{(g)} = \frac{1}{n} \sum_{i=1}^n d(s_i^{(g)}, s_i^{(g-1)})$$

（如果你不是——对应个体，而是“整体替换”，就用群体均值向量 $\mu^{(g)} = \frac{1}{n} \sum_i E(s_i^{(g)})$ ，再算 $d(\mu^{(g)}, \mu^{(g-1)})$ ）

2.3 目标增益（约束改写的主方向）

$$G^{(g)} = \frac{1}{n} \sum_{i=1}^n (F(s_i^{(g)}) - F(s_i^{(g-1)}))$$

2.4 过度收敛惩罚（避免“大家都一样”的坍塌）

收敛可以用多样性下降表示：

$$C^{(g)} = \max(0, D^{(g-1)} - D^{(g)})$$

或用熵下降：

$$C^{(g)} = \max(0, H^{(g-1)} - H^{(g)})$$

3) 每一代创意熵总公式（用于画曲线）

给出一个可解释、可调权重的定义（你可以直接用）：

$$CE^{(g)} = \alpha \cdot \text{clip}(G^{(g)}, -1, 1) + \beta \cdot N^{(g)} + \delta \cdot H^{(g)} - \gamma \cdot C^{(g)}$$

- α : 强调约束方向是否在提升
- β : 强调每代“跳跃/新意”
- δ : 强调群体探索（分散性）
- γ : 惩罚过快收敛（坍缩）

然后你可以画：

- 代际曲线: $CE^{(1)}, CE^{(2)}, \dots, CE^{(G)}$
- 累计创意熵（更像“总创意产出”）: $CE^{cum}(t) = \sum_{g=1}^t CE^{(g)}$

4) “选择-交叉-变异”过程归因指标（你这类 GA 数据最有价值的部分）

你要研究“最终创意熵”，但为了论文更强，一定要能说清楚：创意来自交叉还是变异，还是纯选择导致的收敛。

对每个子代 k （在第 g 代）：

- 父代: $p_{k,1}^{(g)}, p_{k,2}^{(g)}$
- 交叉产物: $c_k^{(g)}$
- 变异产物: $m_k^{(g)}$ （进入下一代的候选）

4.1 交叉贡献（Crossover Novelty Gain）

交叉带来的“脱离父代中心”的程度：

$$CN_k^{(g)} = d(c_k^{(g)}, \text{centroid}(p_{k,1}^{(g)}, p_{k,2}^{(g)}))$$

其中

$$\text{centroid} = \frac{E(p_{k,1}) + E(p_{k,2})}{2}$$

（在 embedding 空间取中心）

群体平均：

$$CN^{(g)} = \frac{1}{n} \sum_{k=1}^n CN_k^{(g)}$$

4.2 变异贡献（Mutation Novelty Gain）

变异相对交叉产物带来的额外新意：

$$MN_k^{(g)} = d(m_k^{(g)}, c_k^{(g)})$$

群体平均：

$$MN^{(g)} = \frac{1}{n} \sum_{k=1}^n MN_k^{(g)}$$

4.3 选择压力 (Selection Pressure / Exploitation)

如果你能得到“被选择的候选”与“全部候选”的 fitness 分布，可以定义经典选择强度：

- 设这一代所有候选 fitness 均值为 $\mu_F^{(g)}$ ，标准差为 $\sigma_F^{(g)}$
- 被选中进入下一代的个体 fitness 均值为 $\mu_{F,sel}^{(g)}$

则：

$$SP^{(g)} = \frac{\mu_{F,sel}^{(g)} - \mu_F^{(g)}}{\sigma_F^{(g)} + \epsilon}$$

SP 越大，越偏“exploitation（追求高分）”，通常会导致多样性下降。

4.4 过程型“遗传创意熵分解”（写论文很强）

你可以把代际新意拆成两部分：

$$N^{(g)} \approx \underbrace{CN^{(g)}}_{\text{交叉}} + \underbrace{MN^{(g)}}_{\text{变异}} - \underbrace{\kappa \cdot SP^{(g)}}_{\text{选择收敛}}$$

κ 是缩放系数（让量纲匹配）。

5) 最终创意熵：同一“句子集 seed”多次 run 的评估

你说“有些组的句子集相同 → 会有不同最终结果”，这就天然支持一个很关键的最终指标：

5.1 同 seed 的最终结果分布熵 (Final Outcome Entropy)

对同一个 seed set，收集多次 run 的最终群体中心向量：

$$\mu^{(G,r)} = \frac{1}{n} \sum_{i=1}^n E(s_i^{(G,r)})$$

(r 是 run index)

定义 run 间的离散度：

$$FOE = \frac{2}{R(R-1)} \sum_{r_1 < r_2} d(\mu^{(G,r_1)}, \mu^{(G,r_2)})$$

或把 $\mu^{(G,r)}$ 聚类成 K 类算 Shannon 熵：

$$FOE_H = - \sum_{k=1}^K q_k \log(q_k + \epsilon)$$

这就是你要的“最终创意熵”最直接的群体定义：

同样的初始句子集，会产生多少种不同的最终创意落点？

6) 给你一个“最终版总分”建议（过程 + 结果统一）

如果你希望用一个标量评估一次 run：

$$CE^{run} = \sum_{g=1}^G CE^{(g)} + \eta \cdot \overline{F}^{(G)}$$

其中 $\overline{F}^{(G)} = \frac{1}{n} \sum_i F(s_i^{(G)})$

然后同 seed 的“最终创意熵”用：

- FOE 或 FOE_H （跨 run 的分布熵）

你拿这套公式可以直接产出的曲线/图

- $CE^{(g)}$ 代际曲线（主图）
- $CN^{(g)}$ vs $MN^{(g)}$ （交叉/变异贡献分解）
- $H^{(g)}$ 或 $D^{(g)}$ （群体多样性随代变化，观测坍缩）
- $SP^{(g)}$ （选择压力与多样性下降的相关性）
- 同 seed 的 FOE （最终创意熵对比：人 vs AI、不同策略组）

1) 基础信息字段（索引 / 分组用）

Excel字段	变量记号	用途
位号	row_id	行索引（可不用）
组	group_id	实验小组（同组通常共同演化）
学号 / 姓名	person_id	个体标识（人类组）
编号	seed_id	初始句编号（建议当“初始句子集”的索引）
原句	$s_i^{(0)}$	第0代/初始个体句子

注：你说“有些组的句子集是相同的”，通常可以用 **同一组 seed_id 的集合** 来定义一个 `seed_set_id`（比如把组内 seed_id 排序后拼成字符串/哈希），用来对齐不同 run 的可比性。

2) 每一轮（第g轮）字段 → 遗传算子变量映射

你的表对每轮都有四列：选择1、选择2、交叉、随机修改（变异）。
用统一记号（第 g 轮, $g = 1 \dots 10$ ）：

- 父代1: $p_{i,1}^{(g)}$
- 父代2: $p_{i,2}^{(g)}$
- 交叉产物: $c_i^{(g)}$
- 变异产物（写回下一代的实际个体句）: $m_i^{(g)}$ （也可记作 $s_i^{(g)}$ ）

关键：表中“随机修改（变异）”列就是这一轮最终产物（下一代的句子），交叉列是变异之前的中间态。

2.1 轮次字段命名规则（非常重要，避免你写错列）

- 选择列：直接写了轮次，不带 .1/.2 后缀
 - 选择1 （第1轮） ... 选择1 （第10轮）
 - 选择2 （第1轮） ... 选择2 （第10轮）
- 交叉 & 变异列：第1轮不带后缀；第2轮开始用 .1，一直到第10轮 .9

2.2 字段对照（给你可直接抄进代码/公式的表）

轮次 g	父代1	父代2	交叉产物	变异产物 (=)
1	选择1 （第1轮）	选择2 （第1轮）	交叉（融合2句形成完整含义，≤30字）	随机修改（变异）
2	选择1 （第2轮）	选择2 （第2轮）	交叉（融合2句形成完整含义，≤30字）.1	随机修改（变异）.1
3	选择1 （第3轮）	选择2 （第3轮）	交叉（融合2句形成完整含义，≤30字）.2	随机修改（变异）.2
4	选择1 （第4轮）	选择2 （第4轮）	交叉（融合2句形成完整含义，≤30字）.3	随机修改（变异）.3
5	选择1 （第5轮）	选择2 （第5轮）	交叉（融合2句形成完整含义，≤30字）.4	随机修改（变异）.4
6	选择1 （第6轮）	选择2 （第6轮）	交叉（融合2句形成完整含义，≤30字）.5	随机修改（变异）.5
7	选择1 （第7轮）	选择2 （第7轮）	交叉（融合2句形成完整含义，≤30字）.6	随机修改（变异）.6
8	选择1 （第8轮）	选择2 （第8轮）	交叉（融合2句形成完整含义，≤30字）.7	随机修改（变异）.7

轮次 g	父代1 $p_{i,1}^{(g)}$	父代2 $p_{i,2}^{(g)}$	交叉产物 $c_i^{(g)}$	变异产物 $m_i^{(g)} (= s_i^{(g)})$
9	选择1 (第9轮)	选择2 (第9轮)	交叉 (融合2句形成完整含义, ≤30字) .8	随机修改 (变异) .8
10	选择1 (第10轮)	选择2 (第10轮)	交叉 (融合2句形成完整含义, ≤30字) .9	随机修改 (变异) .9

3) 过程指标：每个指标用哪些字段（公式输入对照）

下面把你之前要研究的 GA 过程指标，全部写成“用表里哪几列算”。

说明：下面的 $E(\cdot)$ (embedding)、 $F(\cdot)$ (约束目标得分/fitness) 都需要你额外计算后再回填或在代码里在线算；Excel里没有直接给。

3.1 交叉贡献（每轮交叉带来多少“新意”）

对个体 i，第 g 轮：

- 用到字段：选择1 (第g轮)、选择2 (第g轮)、交叉 (...) [对应g]

$$CN_i^{(g)} = d\left(c_i^{(g)}, \text{centroid}(p_{i,1}^{(g)}, p_{i,2}^{(g)})\right)$$

其中

- $p_{i,1}^{(g)}$ = 选择1列
- $p_{i,2}^{(g)}$ = 选择2列
- $c_i^{(g)}$ = 交叉列
- $\text{centroid} = \frac{E(p_1) + E(p_2)}{2}$
- $d(x, y) = 1 - \cos(E(x), E(y))$

群体平均（第g轮）：

$$CN^{(g)} = \frac{1}{n} \sum_i CN_i^{(g)}$$

3.2 变异贡献（在交叉基础上又“跳了多少”）

对个体 i，第 g 轮：

- 用到字段：交叉 (...) [对应g]、随机修改 (变异) [对应g]

$$MN_i^{(g)} = d\left(m_i^{(g)}, c_i^{(g)}\right)$$

群体平均：

$$MN^{(g)} = \frac{1}{n} \sum_i MN_i^{(g)}$$

3.3 代际新意（这一代相对上一代整体跳了多少）

对个体 i:

- 用到字段：随机修改（变异）[对应g-1]、随机修改（变异）[对应g]
- 第0代用 原句

$$N_i^{(g)} = d(s_i^{(g)}, s_i^{(g-1)})$$

其中

- $s_i^{(0)} = \text{原句}$
- $s_i^{(g)} = \text{随机修改（变异）[对应g]}$

群体平均:

$$N^{(g)} = \frac{1}{n} \sum_i N_i^{(g)}$$

3.4 目标增益（约束改写：符合要求的提升）

对个体 i:

- 用到字段：同上（上一代与这一代的最终句子）
- 需要外部计算 fitness: $F(\cdot)$

$$G_i^{(g)} = F(s_i^{(g)}) - F(s_i^{(g-1)})$$

群体平均:

$$G^{(g)} = \frac{1}{n} \sum_i G_i^{(g)}$$

3.5 群体多样性（探索强度）

对第 g 代，直接用所有人的最终句子:

- 用到字段：随机修改（变异）[对应g]（全体行）

方案A（推荐，稳定）平均 pairwise 距离:

$$D^{(g)} = \frac{2}{n(n-1)} \sum_{i < j} d(s_i^{(g)}, s_j^{(g)})$$

方案B（更“熵”）：聚类后 Shannon 熵:

- 用 $E(s_i^{(g)})$ 聚类得占比 $p_k^{(g)}$

$$H^{(g)} = - \sum_k p_k^{(g)} \log(p_k^{(g)} + \epsilon)$$

3.6 收敛惩罚（多样性下降=坍塌到中庸）

- 用到字段：上一代与这一代的群体多样性（由 3.5 算出）

$$C^{(g)} = \max(0, D^{(g-1)} - D^{(g)})$$

或用 H ：

$$C^{(g)} = \max(0, H^{(g-1)} - H^{(g)})$$

4) 最终要画的“每代创意熵曲线”（把字段都串起来）

你最终的过程创意熵（第 g 代）可以直接用：

- 由 3.3、3.4、3.5、3.6 得到

$$CE^{(g)} = \alpha \cdot \text{clip}(G^{(g)}, -1, 1) + \beta \cdot N^{(g)} + \delta \cdot H^{(g)} - \gamma \cdot C^{(g)}$$

然后：

$$CE^{cum}(t) = \sum_{g=1}^t CE^{(g)}$$

画累计曲线最直观。

5) “同一组句子集（相同 seed set）→ 不同最终结果”的最终创意熵

当你把同一个 seed_set_id 跑出多个 run（不同组/不同人/不同AI），你要的“最终创意熵”可以定义成 **run 间结果分布的离散度**：

- 每个 run 的最终群体中心：

$$\mu^{(10,r)} = \frac{1}{n} \sum_i E(s_i^{(10,r)})$$

（字段就是第10轮的 `随机修改（变异）.9`）

- run 间离散度（最终创意熵）：

$$FOE = \frac{2}{R(R-1)} \sum_{r_1 < r_2} d(\mu^{(10,r_1)}, \mu^{(10,r_2)})$$